

Métodos Numéricos I

Tema 4. Ajuste de Curvas. Mínimos Quadrados.

Prof. Dany S. Dominguez
dsdominguez@gmail.br
Sala 1 – NBCGIB
(73) 3680 5212 – ramal 30

ROTEIRO


- Introdução
- Regressão linear
- Linearização de funções não-lineares
- Regressão polinomial
- Regressão múltipla
- Modelo geral de mínimos quadrados
- Comentários finais

Problemas em ajuste de curvas

- Conjunto de valores discretos
 - Os dados são conhecidos em um conjunto discreto de valores
 - Deseja-se conhecer valores em pontos que não pertencem ao conjunto
 - Devemos obter uma função (modelo) que descreva o comportamento dos dados
- Funções complexas
 - Temos uma função de alto custo computacional, derivadas desconhecidas ou de alto custo, não integrável
 - Avaliamos a função em pontos do intervalo de interesse
 - Obtemos uma função mais simples que descreva os dados


Abordagens

- A abordagem utilizada no ajuste depende da incerteza (ou erro) presente nos dados
- Regressão por mínimos quadrados
 - Dados apresentam grau significativo de erros (ruído)
 - Isto ocorre geralmente com dados experimentais
 - Procura-se uma curva que represente a tendência geral dos dados
 - Os pontos individuais não precisam satisfazer a função encontrada



Abordagens

- Interpolação
 - Os dados disponíveis são muito precisos
 - Dados produto de análises estatísticas ou gerados por uma função
 - Encontrar uma função (ou várias funções) que satisfaçam cada um dos pontos
 - Chamamos interpolação à estimativa entre pontos discretos
- Chamamos extrapolação o cálculo de estimativas fora do intervalo de dados
- O uso de modelos na condição de extrapolação deve ser feito cuidadosamente




Aplicações ajuste de curvas

- Análise de tendências
 - Previsão de valores da variável de dependente
- Teste de hipótese
 - Encontrar ou validar um modelo para os dados
 - Geralmente envolve calcular os coeficientes do modelo
- Aproximação de funções complicadas


Regressão por mínimos quadrados

- Dado o seguinte conjunto de dados experimentais
- Os valores sugerem que a valores mais altos de x correspondem valores mais altos de y
- Função crescente
- Oscilações




Regressão por mínimos quadrados

- Podemos ajustar os dados utilizando interpolação polinomial
- O polinômio interpolador passa exatamente por todos os pontos
- Os valores interpolados entre 5,5 e 6 não correspondem aos dados
- Motivos:
 - Elevado grau do polinômio
 - Incerteza nos dados



Regressão por mínimos quadrados

- Outra estratégia é encontrar uma função aproximada que ajuste a tendência geral dos dados
- A reta não satisfaz exatamente o conjunto de dados
- Reproduz o comportamento na região de interesse
- Como determinar a função de ajuste?
- **Regressão por MQ:** visa determinar uma curva que minimize as discrepâncias entre os dados e os pontos da curva.



ROTEIRO

- Introdução
- **Regressão linear**
- Linearização de funções não-lineares
- Regressão polinomial
- Regressão múltipla
- Modelo geral de mínimos quadrados
- Comentários finais

Regressão linear

- A alternativa mais simples de regressão por MQ é a regressão linear
- Problema: Ajustar o conjunto de pontos $(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)$ a reta

$$y = a_0 + a_1x + e$$

- a_0 , coeficiente de interseção
 - a_1 , pendente ou inclinação da reta
 - e , erro ou resíduo
- Resíduo: discrepância entre o valor verdadeiro (y) e o valor aproximado pela reta

$$e = y - a_0 - a_1x$$

Regressão linear

- Qual critério podemos utilizar para minimizar o resíduo e obter uma função de ajuste única?


1. Minimizar a soma dos erros para todos os pontos disponíveis

$$\sum_{i=1}^n e_i = \sum_{i=1}^n (y_i - a_0 - a_1 x_i) \quad (1)$$

- Considere o ajuste de uma reta a dois pontos
- O melhor ajuste é a reta que une os dois pontos
- Qualquer reta que passe pelo ponto médio do segmento que liga os pontos resulta no valor mínimo da eq. (1)
- Os erros de sinais diferentes cancelam-se

Regressão linear

- Como minimizar o resíduo . . .
 1. Minimizar a soma dos erros . . .




- Infinitas soluções
- Alguns ajustes não representam os dados
- Como evitar o cancelamento dos resíduos?

Regressão linear

- Como minimizar o resíduo . . .
2. Minimizar a soma dos valores absolutos das discrepâncias

$$\sum_{i=1}^n |e_i| = \sum_{i=1}^n |y_i - a_0 - a_1 x_i| \quad (2)$$

- Considere o ajuste de uma reta a 4 pontos
- Qualquer reta passando entre as retas tracejadas minimiza a eq. (2)
- Infinitas soluções




Regressão linear

- Como minimizar o resíduo . . .
3. Critério minimax: escolher a reta que minimize a distância máxima que um ponto individual tenha com a reta de ajuste

$$\min_{(reta)} \left[\max_{i=1:n} |e_i| \right] \quad (3)$$

- Amplifica a influência de pontos com elevada incerteza
- Melhor (linha contínua)
- Minimax (linha tracejada)



Regressão linear

- Como minimizar o resíduo . . .

4. Minimizar a soma do quadrado dos resíduos

$$\begin{aligned} S_r &= \sum_{i=1}^n e_i^2 = \sum_{i=1}^n \left(y_{i,dados} - y_{i,modelo} \right)^2 \\ &= \sum_{i=1}^n \left(y_i - a_0 - a_1 x_i \right)^2 \quad (4) \end{aligned}$$

- S_r soma do quadrado dos resíduos
 - Este critério fornece um ajuste único
 - O erro de ajuste é minimizado para todos os pontos
-
- Como determinar os valores de a_0 e a_1 que minimizem a eq. (4)?

Regressão linear

- Derivamos a eq. (4) em relação a cada coeficiente

$$\frac{\partial S_r}{\partial a_0} = -2 \sum (y_i - a_0 - a_1 x_i)$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum [(y_i - a_0 - a_1 x_i) x_i]$$

- Para simplificar a notação $\sum \Rightarrow \sum_{i=1}^n$
- Para obter o mínimo de S_r igualamos as derivadas a zero

$$0 = \sum y_i - \sum a_0 - a_1 \sum x_i$$

$$0 = \sum y_i x_i - a_0 \sum x_i - a_1 \sum x_i^2$$

Regressão linear

- Escrevemos as eqs anteriores como um SELA com incógnitas a_0 e a_1

$$(n)a_0 + \left(\sum x_i\right)a_1 = \sum y_i$$

$$\left(\sum x_i\right)a_0 + \left(\sum x_i^2\right)a_1 = \sum y_i x_i$$

- Resolvendo obtemos as expressões para calcular os coeficientes


$$a_0 = \frac{\sum y_i - a_1 \sum x_i}{n} = \bar{y} - a_1 \bar{x} \quad (5)$$

$$a_1 = \frac{n \sum (y_i x_i) - \sum x_i \sum y_i}{n \sum x_i^2 - \left(\sum x_i\right)^2} \quad (6)$$

Regressão linear

- **Exemplo 1:** Ajuste uma reta aos valores (x, y) da tabela abaixo

x_i	y_i
1,00	0,50
2,00	2,50
3,00	2,00
4,00	4,00
5,00	3,50
6,00	6,00
7,00	5,50



- Arquivo Excel

$$n = 7$$

$$a_1 = 0,83929 \quad a_0 = 0,07143 \quad y = 0,07143 + 0,83929x$$

Regressão linear

- Como quantificar o erro da reta de ajuste?
- Da estatística básica, a soma total dos quadrados dos resíduos em relação à média, é definida por

$$S_t = \sum (y_i - \bar{y})^2 \quad (7)$$

- Na regressão linear temos

$$S_r = \sum (y_i - a_0 - a_1 x_i)^2 \quad (8)$$

- A eq. (7) caracteriza o erro residual em relação ao valor médio do conjunto, antes da regressão
- A eq. (8) caracteriza o erro residual em relação à reta de ajuste, depois da regressão

Regressão linear

- A diferença $(S_t - S_r)$ quantifica a redução do erro decorrente de descrever os dados usando uma reta e não o valor médio,

- Definimos então:

$$r^2 = \frac{S_t - S_r}{S_t}$$

- r^2 coeficiente de determinação
 - r coeficiente de correlação
- Quais valores de r descrevem um ajuste perfeito (ruim)?

Regressão linear

- Ajuste perfeito
 - $S_r = 0, r^2 = r = 1$
 - A reta reproduz perfeitamente o comportamento dos dados
- Ajuste ruim
 - $S_r = S_p, r^2 = r = 0$
 - A reta NÃO reproduz perfeitamente o comportamento dos dados
 - O ajuste não melhora a descrição dos dados em relação à média

Regressão linear

- **Exemplo 2:** Avalie a qualidade do ajuste para o exemplo 1

- Arquivo Excel

$$\bar{y} = 3,4286$$

$$S_t = 22,714$$

$$S_r = 2,9911$$

$$r^2 = 0,8683$$

$$r = 0,9318$$


- O ajuste obtido descreve apropriadamente os dados

ROTEIRO


- Introdução
- Regressão linear
- Linearização de funções não-lineares
- Regressão polinomial
- Regressão múltipla
- Modelo geral de mínimos quadrados
- Comentários finais

Funções não-lineares

- A regressão linear oferece uma técnica simples para ajustar uma reta aos dados
- Pressupõe que a relação entre a variável dependente e a independente, é linear
- Alguns dados não tem dependência linear
- Nesses casos um ajuste curvilíneo é preferível
 - Regressão polinomial
 - Modelos não lineares



(a)



(b)

Funções não-lineares




- Em funções não-lineares que envolvam um ou dois parâmetros
- Podemos utilizar transformações para expressar a função em forma lineal
- Em seguida, aplicar a regressão linear
- Esta técnica é conhecida como linearização da função
- Vejamos alguns exemplos

Funções não-lineares

- Modelo exponencial $y = \alpha_1 e^{\beta_1 x}$
 - α_1, β_1 constantes (parâmetros do modelo)
 - Descreve fenômenos onde a variável dependente aumenta (ou diminui) proporcionalmente a seu valor absoluto
 - Exemplos:
 - Crescimento populacional
 - Decaimento radiativo
 - Para linearizar, aplicamos logaritmo natural
$$y^* = \ln \alpha_1 + \beta_1 x \quad (9)$$
 - sendo $y^* = \ln y, \quad a_0 = \ln \alpha_1, \quad a_1 = \beta_1$

Funções não-lineares

- Modelo exponencial . . .



Funções não-lineares

- Equação de potencia simples $y = \alpha_2 x^{\beta_2}$
 - α_2, β_2 constantes
 - Exemplos:
 - Crescimento de cristais e polímeros
 - Reações químicas
 - Para linearizar, aplicamos logaritmo base 10




$$y^* = \log \alpha_2 + \beta_2 x^* \quad (10)$$

– sendo

$$y^* = \log y, \quad x^* = \log x, \quad a_0 = \log \alpha_2, \quad a_1 = \beta_2$$

Funções não-lineares

- Equação de potência simples. . .



Funções não-lineares

- Modelo de taxa de crescimento de saturação

$$y = \alpha_3 \frac{x}{\beta_3 + x}$$

– α_3, β_3 constantes

– Exemplos:

- Crescimento populacional em condições limitantes
- Reações químicas

– Para linearizar, invertamos a equação




$$y^* = \frac{\beta_3}{\alpha_3} x^* + \frac{1}{\alpha_3} \quad (11)$$

– sendo

$$y^* = \frac{1}{y}, \quad x^* = \frac{1}{x}, \quad a_0 = \frac{1}{\alpha_3}, \quad a_1 = \frac{\beta_3}{\alpha_3}$$

Funções não-lineares

- Equação de crescimento com saturação. . .




- Considerando os modelos transformados (eqs. (9, 10, 11)) podemos usar a regressão linear para calcular α_0 e α_1
- Depois, utilizamos a transformação inversa para determinar α e β

Funções não-lineares

- **Exemplo 3:** Considerando os dados da tabela abaixo obtenha um ajuste para a equação de potencia $y = \alpha x^\beta$

x_i	y_i
1,00	0,50
2,00	1,70
3,00	3,40
5,00	5,70
6,00	8,40



Funções não-lineares

- **Exemplo 3 . . .**


- Modelo linearizado

$$y^* = \log \alpha + \beta x^* = a_0 + a_1 x$$

- Transformações (Excel)

$$y^* = \log y, \quad x^* = \log x$$

x_i	y_i
0,00	-0,30
0,30	0,23
0,48	0,53
0,70	0,76
0,78	0,92




Funções não-lineares

- **Exemplo 3 . . .**

- Aplicando regressão linear (Excel)

$$a_0 = -0,3002$$

$$a_1 = 1,7517$$



Funções não-lineares


- **Exemplo 3 . . .**

- Calculamos os parâmetros do modelo

$$\alpha = 10^{a_0} = 0,5009$$

$$\beta = 1,7517$$

$$y = 0,5009x^{1,7517}$$



ROTEIRO

- Introdução
- Regressão linear
- Linearização de funções não-lineares
- **Regressão polinomial**
- Regressão múltipla
- Modelo geral de mínimos quadrados
- Comentários finais

Regressão polinomial

- Temos estudado procedimentos para ajustar dados a uma reta
- Muitos conjuntos de dados não são descritos de forma satisfatória por uma reta
- Nesses casos um ajuste *curvilíneo* deve ser utilizado
- Se desejarmos mais de dois parâmetros, obtemos esse tipo de ajuste utilizando a regressão polinomial
- O procedimento de mínimos quadrados pode ser estendido para polinômios de grau mais alto

Regressão polinomial

- Ilustramos o procedimento para o polinômio quadrático

$$y = a_0 + a_1x + a_2x^2 + e$$

- Considerando um conjunto de n pontos, a soma do quadrado dos resíduos aparece como

$$S_r = \sum e_i^2 = \sum \left(y_i - a_0 - a_1x_i - a_2x_i^2 \right)^2$$

- A partir deste ponto seguimos o mesmo procedimento da regressão linear. Qual?
 - Derivar o quadrado dos resíduos em relação aos coeficientes do modelo
 - Igualamos as derivadas a zero e resolvemos o SELA associado

Regressão polinomial

- Para minimizarmos o resíduo, calculamos as derivadas de S_r com relação a a_0 , a_1 e a_2

$$\frac{\partial S_r}{\partial a_0} = -2 \sum \left(y_i - a_0 - a_1 x_i - a_2 x_i^2 \right)$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum \left[\left(y_i - a_0 - a_1 x_i - a_2 x_i^2 \right) x_i \right]$$

$$\frac{\partial S_r}{\partial a_2} = -2 \sum \left[\left(y_i - a_0 - a_1 x_i - a_2 x_i^2 \right) x_i^2 \right]$$

Regressão polinomial

- Calculamos o mínimo igualando a zero e agrupando

$$(n)a_0 + \left(\sum x_i\right)a_1 + \left(\sum x_i^2\right)a_2 = \sum y_i$$

$$\left(\sum x_i\right)a_0 + \left(\sum x_i^2\right)a_1 + \left(\sum x_i^3\right)a_2 = \sum y_i x_i$$

$$\left(\sum x_i^2\right)a_0 + \left(\sum x_i^3\right)a_1 + \left(\sum x_i^4\right)a_2 = \sum y_i x_i^2$$

- Em notação matricial

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum y_i x_i \\ \sum y_i x_i^2 \end{bmatrix}$$

Regressão polinomial

- Obtemos um sistema de três equações em três incógnitas
- Pode ser resolvido utilizando técnicas de resolução de SELAs
- O caso quadrático pode ser facilmente estendido para um polinômio de grau m

$$y = a_0 + a_1x + a_2x^2 + \cdots + a_mx^m + e$$

- A soma do quadrado dos resíduos escreve-se

$$S_r = \sum e_i^2 = \sum \left(y_i - a_0 - a_1x_i - a_2x_i^2 - \cdots - a_mx_i^m \right)^2$$

Regressão polinomial

- Seguindo um procedimento semelhante
 - Calculamos as derivadas em relação aos coeficientes a_i
 - Igualando a zero e agrupando
 - Obtemos o seguinte sistema

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 & \cdots & \sum x_i^m \\ \sum x_i & \sum x_i^2 & \sum x_i^3 & \cdots & \sum x_i^{m+1} \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 & \cdots & \sum x_i^{m+2} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \sum x_i^m & \sum x_i^{m+1} & \sum x_i^{m+2} & \cdots & \sum x_i^{2m} \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \\ \vdots \\ a_m \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum y_i x_i \\ \sum y_i x_i^2 \\ \vdots \\ \sum y_i x_i^m \end{bmatrix}$$

- O problema de obter o polinômio de ajuste de grau m , se reduz, a resolver um SELA de ordem $m+1$

Regressão polinomial

- Temos uma matriz simétrica
- Matriz mal condicionada (grandes diferenças entre as ordens dos coeficientes)
- Para termos um ajuste de grau m são necessários pelo menos $m+1$ pontos
- Entretanto, o uso de polinômios de alta ordem não é recomendável
 - Polinômios de alta ordem apresentam comportamento oscilatório (indesejado)
- Por este motivo as matrizes de MQ geralmente são pequenas

Regressão polinomial

- Quais métodos de resolução de SELAs é apropriado para resolver a matriz de MQ?
 - Métodos diretos
 - Eliminação de Gauss com pivotamento
 - Pode falhar para matrizes mal condicionadas (m grande)
- Qual a estratégia apropriada para montagem da matriz de MQ?
 - Aproveitar a estrutura simétrica
 - Calcular as potencias de forma acumulativa $(x_i, x_i^2, x_i^3, \dots, x_i^m)$
- **Desafio:** propor um algoritmo para montagem da matriz de MQ com dimensão arbitrária com o mínimo de operações possível (Enviar por email).

Regressão polinomial

- Da mesma forma que na regressão lineal a qualidade do ajuste polinomial pode ser avaliada a través do coeficiente de determinação r^2
- **Exemplo 4:** Ajuste um polinômio de segundo grau aos seguintes dados


x_i	y_i
0,00	2,10
1,00	7,70
2,00	13,60
3,00	27,20
4,00	40,90
5,00	61,10

Avalie a qualidade do ajuste.

Regressão polinomial

- Exemplo 4 . . .

x_i	y_i
0,00	2,10
1,00	7,70
2,00	13,60
3,00	27,20
4,00	40,90
5,00	61,10



– Matriz do sistema (Excel)

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum y_i x_i \\ \sum y_i x_i^2 \end{bmatrix} \quad \begin{bmatrix} 6 & 15 & 55 \\ 15 & 55 & 225 \\ 55 & 225 & 979 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} 152,6 \\ 585,6 \\ 2488,8 \end{bmatrix}$$

Regressão polinomial


- **Exemplo 4 . . .**

- Resolução do sistema

$$a_0 = 2,4786 \quad a_1 = 2,3593 \quad a_2 = 1,8607$$

- Função de ajuste

$$y = 2,4786 + 2,3593x + 1,8607x^2$$



Regressão polinomial

- **Exemplo 4 . . .**

- Calculo do coeficiente de determinação

$$r^2 = \frac{S_t - S_r}{S_t}$$

$$S_t = 2513,39$$

$$S_r = 3,75$$

$$r^2 = 0,9985$$

$$r = 0,9993$$

- O ajuste quadrático descreve satisfatoriamente os dados

Regressão polinomial - Algoritmo

ENTRADA : ordem do polinômio de ajuste m
numero de pontos n
pontos de ajuste $(x_i, y_i) \ i=1:n$

SAÍDA : Coeficientes do polinomio a_0, a_1, \dots, a_m
ou mensagem de falha

PASSO 1 : Se $(n > m+1)$

Saída(Regressão impossível), FIM

PASSO 2 : Montagem da matriz aumentada de MQ

PASSO 3 : Resolução do SELA

PASSO 4 : Saída (a_0, \dots, a_m) , FIM

ROTEIRO

- Introdução
- Regressão linear
- Linearização de funções não-lineares
- Regressão polinomial
- **Regressão múltipla**
- Modelo geral de mínimos quadrados
- Comentários finais

Regressão linear múltipla

- O ajuste de curvas pode ser estendido no caso de y ser uma função de duas ou mais variáveis independentes
- Poderíamos considerar funções de qualquer ordem (linear, quadrática, cubica)
- Por simplicidade, o ajuste mais utilizado é a regressão linear múltipla
- Considere y , uma função linear das variáveis independentes x_1 e x_2 na forma

$$y = a_0 + a_1x_1 + a_2x_2 + e$$

- Dados n os pontos

$$(x_{11}, x_{21}, y_1), (x_{12}, x_{22}, y_2), \dots, (x_{1n}, x_{2n}, y_n)$$

Regressão linear múltipla

- Como calcular os coeficientes da RLM?
 - Escrever a expressão do quadrado dos resíduos
 - Derivar a expressão em relação aos coeficientes
 - Conformar um sistema de eqs. igualando as derivadas a zero
 - Obter os coeficientes resolvendo o sistema
- Como avaliar a qualidade do ajuste?
 - Calcular os coeficientes de determinação e correlação
- **Atividade:** Obtenha a matriz de MQ para regressão linear múltipla (Deverá anexar este desenvolvimento na questão 2 da lista)

Regressão linear múltipla

- Matriz de regressão linear múltipla

$$y = a_0 + a_1x_1 + a_2x_2 + e$$

$$\begin{bmatrix} n & \sum x_{1i} & \sum x_{2i} \\ \sum x_{1i} & \sum x_{1i}^2 & \sum x_{1i}x_{2i} \\ \sum x_{2i} & \sum x_{1i}x_{2i} & \sum x_{2i}^2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum y_i x_{1i} \\ \sum y_i x_{2i} \end{bmatrix}$$

ROTEIRO

- Introdução
- Regressão linear
- Linearização de funções não-lineares
- Regressão polinomial
- Regressão múltipla
- **Modelo geral de mínimos quadrados**
- Comentários finais

Formulação Geral de MQ

- Estudamos três tipos de regressão
 - linear simples, polinomial, linear múltipla
- Todos os tipos de regressão pertencem à formulação geral de mínimos quadrados

$$y = a_0 z_0 + a_1 z_1 + a_2 z_2 + \cdots + a_m z_m + e \quad (12)$$

- a_k são os coeficientes de ajuste
 - z_k são as funções base
- Para regressão linear simples
$$z_0 = 1, z_1 = x, z_{2:m} = 0$$
- Para regressão polinomial
$$z_0 = 1, z_1 = x, z_2 = x^2, \dots, z_m = x^m$$

Formulação Geral de MQ

- A formulação geral aplica-se a ajustes lineares, refere-se apenas a como o modelo depende dos parâmetros a_k coeficientes
- As funções base podem ser não-lineares (regressão polinomial)
- Outras funções bases não-lineares são:
$$z_0 = 1, z_1 = \cos(\omega t), , z_2 = \sin(\omega t), z_{3:m} = 0$$

que representam a aproximação de Fourier na forma

$$y = a_0 + a_1 \cos(\omega t) + a_2 \sin(\omega t) + e$$
- Em resumo a eq. (12) representa uma formulação geral que inclui todos os tipos de ajuste (**lineares**)

Formulação Geral de MQ

- Considerando n pontos de dados a eq. (12) pode ser escrita em notação matricial na forma

$$\{Y\} = [Z]\{A\} + \{E\}$$

- $\{Y\}$ é o vetor coluna dos valores observados da variável dependente em n pontos

$$\{Y\}^T = [y_1, y_2, \dots, y_n]$$

- $[Z]$ é a matriz dos valores calculados das $(m+1)$ funções base nos valores medidos (variáveis independentes) para os n pontos

Formulação Geral de MQ

$$[Z] = \begin{bmatrix} z_{01} & z_{11} & \cdots & z_{m1} \\ z_{02} & z_{12} & \cdots & z_{m2} \\ \vdots & \vdots & & \vdots \\ z_{0n} & z_{1n} & \cdots & z_{mn} \end{bmatrix}_{n \times (m+1)}$$

- linhas: n pontos
- colunas: $m+1$ funções base
- Z não é uma matriz quadrada
- $\{A\}$ vetor coluna dos coeficientes de ajuste

$$\{A\}^T = [a_0, a_1, \cdots, a_m]$$

Formulação Geral de MQ

- $\{E\}$ vetor coluna dos resíduos

$$\{E\}^T = [e_1, e_2, \dots, e_n]$$

- Na formulação geral, a soma do quadrado dos resíduos é definida como

$$S_r = \sum_{i=1}^n \left(y_i - \sum_{j=0}^m a_j z_{ji} \right)^2$$

- A soma dos resíduos é minimizada quando
 - Calculamos as derivadas parciais em relação aos coeficientes a_k
 - Igualamos as condições resultantes a zero obtendo um sistema de equações

Formulação Geral de MQ

- O resultado deste processo escreve-se como

$$\left[[Z]^T [Z] \right] \{A\} = \left\{ [Z]^T \{Y\} \right\} \quad (13)$$

- A eq. (13) representa o SELAs para calcular os coeficientes da regressão para uma família de funções base e um conjunto de dados
- **Exemplo 5:** Mostre que a formulação de mínimos quadrados generalizada inclui a regressão polinomial quadrática $y = a_0 + a_1x + a_2x^2 + e$

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum y_i x_i \\ \sum y_i x_i^2 \end{bmatrix}$$

Formulação Geral de MQ

- **Exemplo 5 . . .**

- As funções base para a regressão polinomial com $m=2$

$$z_0 = 1, z_1 = x, z_2 = x^2, z_{3:m} = 0$$

- Considerando n pontos a formulação geral

$$\{Y\} = [Z]\{A\} + \{E\}$$

aparece como

$$\begin{Bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{Bmatrix} = \begin{bmatrix} 1 & x_1 & x_1^2 \\ 1 & x_2 & x_2^2 \\ \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 \end{bmatrix}_{n \times 3} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} + \begin{Bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{Bmatrix}$$

Formulação Geral de MQ

- **Exemplo 5 . . .**

- Calculamos $[Z]^T$

$$[Z]^T = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \\ x_1^2 & x_2^2 & \cdots & x_n^2 \end{bmatrix}_{3 \times n}$$

- Multiplicamos $[Z]^T [Z]$

$$[[Z]^T [Z]] = \begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix}_{3 \times 3}$$

Formulação Geral de MQ

- **Exemplo 5 . . .**

- Multiplicamos $[Z]^T \{Y\}$

$$[Z]^T \{Y\} = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \\ x_1^2 & x_2^2 & \cdots & x_n^2 \end{bmatrix}_{3 \times n} \begin{Bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{Bmatrix} = \begin{Bmatrix} \sum y_i \\ \sum y_i x_i \\ \sum y_i x_i^2 \end{Bmatrix}$$

Formulação Geral de MQ

- **Exemplo 5 . . .**

- Considerando a expressão do SELA

$$\left[[Z]^T [Z] \right] \{A\} = \left\{ [Z]^T \{Y\} \right\}$$

$$\begin{bmatrix} n & \sum x_i & \sum x_i^2 \\ \sum x_i & \sum x_i^2 & \sum x_i^3 \\ \sum x_i^2 & \sum x_i^3 & \sum x_i^4 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} \sum y_i \\ \sum y_i x_i \\ \sum y_i x_i^2 \end{bmatrix}$$

- Praticamente todas as abordagens de ajustes por mínimos quadrados podem ser representadas pela formulação geral
- Ademais, a formulação geral oferece um mecanismo simples para calcular a matriz do SELA

ROTEIRO

- Introdução
- Regressão linear
- Linearização de funções não-lineares
- Regressão polinomial
- Regressão múltipla
- Modelo geral de mínimos quadrados
- **Comentários finais**

Comentários Finais

- O ajuste de curvas é utilizado para
 - obter funções que descrevam o comportamento de conjuntos de dados
 - construção e aceitação de modelos
 - simplificar funções complexas
- Uma das alternativas mais utilizadas é o ajuste onde o quadrado da soma dos resíduos é minimizado (mínimos quadrados)
- Obtemos a expressão que minimiza a soma dos resíduos
 - derivando em relação aos coeficientes de ajuste
 - igualando a zero e construindo um SELA

Comentários Finais

- Etapas do ajuste
 1. Plotar o conjunto de dados
 2. Identificar tendências e escolher a função de ajuste
 - regressão linear
 - regressão polinomial
 3. Construção da matriz de mínimos quadrados
 - Alto custo computacional
 - Enfoque acumulativo ou formulação geral
 4. Obter os coeficientes resolvendo o sistema
 - matrizes mal condicionadas
 - métodos diretos
 5. Avaliar a qualidade do ajuste

Comentários Finais

- A qualidade do ajuste pode ser avaliado usando o coeficiente de determinação e/ou correlação
- Para dados que não se ajustem ao modelo linear
 - Escolher modelo não-linear
 - Linearizar usando transformações
 - Resolver por regressão simples
- Se o modelo não pode ser linearizado
 - Utilizar regressão não-linear (não abordado)
 - Método de Gauss-Newton (não abordado)

Comentários Finais

- Os métodos de regressão por mínimos quadrados
 - Estreitamente ligados com o processamento estatístico de dados
 - Apenas ilustramos os métodos utilizando um enfoque prático
 - Os fundamentos teóricos dos métodos de regressão envolvem fundamentos de estatística